

# Métodos de Otimização e Máquinas de Vetores Suporte

## Qualificação de Trabalho de Conclusão de Curso

Paula Cristina Rohr Ertel\*

Orientador: Luiz Rafael dos Santos

Universidade Federal de Santa Catarina - Campus Blumenau

18 de Novembro de 2019

## 1 Introdução às Máquinas de Vetores Suporte

A Aprendizagem de Máquina (do inglês *Machine Learning*) é o estudo do uso de técnicas computacionais para automaticamente detectar padrões em dados e usá-los para fazer previsões e tomar decisões. De acordo com Krulikovski [3], existem dois tipos de Aprendizagem de Máquina, a aprendizagem supervisionada, em que a partir de um conjunto de dados de entrada e saída a máquina constrói um modelo que deduz a saída para novas entradas, e a não supervisionada, na qual a máquina cria sua própria solução.

A aprendizagem supervisionada é composta por uma etapa denominada fase de treinamento, na qual é dado um conjunto de treinamento formado por vários dados de entrada e saída que funcionam como exemplos, a partir dos quais a máquina detecta padrões e cria um modelo para deduzir a saída de novos dados. Após essa fase novas entradas são testadas, denominadas conjunto de teste, no intuito de analisar se a máquina está gerando as saídas corretas. Algumas técnicas para aprendizagem de máquina supervisionada são as Máquinas de Vetores Suporte, Regressão Linear, Regressão Logística e Redes Neurais. Enquanto que a *Singular Value Decomposition* (SVD), Clusterização e

---

\*Acadêmica do curso de Licenciatura em Matemática/UFSC-Blumenau

Análise de Componentes Principais [3] são exemplos de técnicas para a aprendizagem não supervisionada.

As Máquinas de Vetores Suporte (SVM, do inglês *Support Vector Machine*), conforme mencionado por Krulikovski [3], são indicadas nos casos em que ocorrem dados de dimensões elevadas e com altos níveis de ruídos, além de apresentar uma boa capacidade de generalização. Esta técnica pode ser aplicada tanto para problemas de regressão como de classificação. Segundo Krulikovski [3], essa técnica foi desenvolvida por Vladimir Vapnik, Bernhard Boser, Isabelle Guyon e Corrina Cortes, com base na Teoria de Aprendizagem Estatística. Algumas aplicações de SVM em problemas práticos são o reconhecimento facial, leitura de placas automotivas e detecção de spam.

Agora, vamos formular matematicamente o problema de classificação utilizando as Máquinas de Vetores Suporte. Para tanto, considere um conjunto de dados, pertencentes a duas classes distintas, conforme Figura 1.



Figura 1: Dados lineares, com margem flexível e não lineares.

Fonte: Krulikovski [3]

Observe que na Figura 1a os dados podem ser classificados corretamente através de uma reta. Já na Figura 1b é possível encontrar uma reta que separa alguns poucos dados, porém incorretamente. E na Figura 1c não é possível classificar os dados como nos casos anteriores. Nestes exemplos temos representados os três casos de SVM: o linear com margem rígida, o linear com margem flexível e o não linear, respectivamente.

A modelagem do problema de classificação, utilizando a técnica de SVM, consiste em encontrar um hiperplano ótimo que melhor separe os dados de entrada  $x^i$  em duas saídas  $y_i$  através de uma função de decisão. Matematicamente, mostraremos que trata-se um problema de programação quadrática convexa com restrições lineares, que pode ser

formulado como

$$\begin{aligned} \min_{w,b} \quad & f(w) \\ \text{s.a.} \quad & g(w, b) \leq 0, \end{aligned}$$

com  $w \in \mathbb{R}^n$  e  $b \in \mathbb{R}$ , em que  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  é uma função quadrática e  $g : \mathbb{R}^{n+1} \rightarrow \mathbb{R}^m$  é linear. Note também que  $f$  e  $g$  são continuamente diferenciáveis.

Para formular matematicamente o problema de classificação, considere os conjuntos de entrada  $\mathcal{X} = \{x^1, \dots, x^m\} \subset \mathbb{R}^n$  e de treinamento  $\mathcal{Y} = \{(x^1, y_1), \dots, (x^m, y_m) \mid x^i \in \mathcal{X} \text{ e } y_i \in \{-1, 1\}\}$ , com a partição

$$\mathcal{X}^+ = \{x^i \in \mathcal{X} \mid y_i = 1\} \quad \text{e} \quad \mathcal{X}^- = \{x^i \in \mathcal{X} \mid y_i = -1\},$$

dos conjuntos formados pelos atributos pertencentes às classes positiva e negativa, respectivamente.

**Definição 1.** Considere um vetor não nulo  $w \in \mathbb{R}^n$  e um escalar  $b \in \mathbb{R}$ . Um hiperplano com vetor normal  $w$  e constante  $b$  é um conjunto da forma  $\mathcal{H}(w, b) = \{x \in \mathbb{R}^n \mid w^T x + b = 0\}$ .

O hiperplano  $\mathcal{H}(w, b)$  divide o espaço  $\mathbb{R}^n$  em dois semiespaços, dados por

$$\mathcal{S}^+ = \{x \in \mathbb{R}^n \mid w^T x + b \geq 0\} \quad \text{e} \quad \mathcal{S}^- = \{x \in \mathbb{R}^n \mid w^T x + b \leq 0\}.$$

Considere dois conjuntos de dados de treinamento representados no  $\mathbb{R}^2$  como na Figura 2a, em que os pontos em azul representam a classe positiva, e os pontos em vermelho a classe negativa. Perceba na Figura 2b que todos os hiperplanos representados separam corretamente os dados, porém nosso objetivo será encontrar o hiperplano que melhor separa esses dados, o qual está representado na Figura 3a pela cor violeta. Logo, desejamos encontrar o hiperplano que possibilita a maior faixa que não contém nenhum dado, pois caso a faixa seja muito estreita pequenas perturbações no hiperplano ou no conjunto de dados podem resultar uma classificação incorreta.

**Definição 2.** Os conjuntos  $\mathcal{X}^+, \mathcal{X}^- \subset \mathbb{R}^n$  são ditos linearmente separáveis quando existem  $w \in \mathbb{R}^n$  e  $b \in \mathbb{R}$  tais que  $w^T x + b > 0$  para todo  $x \in \mathcal{X}^+$  e  $w^T x + b < 0$  para todo  $x \in \mathcal{X}^-$ . O hiperplano  $\mathcal{H}(w, b)$  é chamado hiperplano separador dos conjuntos  $\mathcal{X}^+$  e  $\mathcal{X}^-$ .

**Lema 1.** Suponha que os conjuntos  $\mathcal{X}^+, \mathcal{X}^- \subset \mathbb{R}^n$  são finitos e linearmente separáveis, com hiperplano separador  $\mathcal{H}(w, b)$ . Então, existem  $\bar{w} \in \mathbb{R}^n$  e  $\bar{b} \in \mathbb{R}$  tais que  $\mathcal{H}(\bar{w}, \bar{b})$



Figura 2: Conjunto de Dados e Hiperplanos.  
 Fonte: Krulikovski [3]



Figura 3: Hiperplano Ótimo.  
 Fonte: Krulikovski [3]

pode ser descrito por

$$\bar{w}^T x + \bar{b} = 0,$$

satisfazendo

$$\bar{w}^T x + \bar{b} \geq 1, \text{ para todo } x \in \mathcal{X}^+, \quad (1)$$

$$\bar{w}^T x + \bar{b} \leq -1, \text{ para todo } x \in \mathcal{X}^-. \quad (2)$$

*Demonstração.* Pela Definição 2, temos que existem  $w \in \mathbb{R}^n$  e  $b \in \mathbb{R}$  tais que

$$w^T x + b > 0, \text{ para todo } x \in \mathcal{X}^+,$$

$$w^T x + b < 0, \text{ para todo } x \in \mathcal{X}^-.$$

Como  $\mathcal{X}^+ \cup \mathcal{X}^-$  é um conjunto finito, podemos definir

$$\gamma := \min_{x \in \mathcal{X}^+ \cup \mathcal{X}^-} |w^T x + b| > 0.$$

Portanto, para todo  $x \in \mathcal{X}^+ \cup \mathcal{X}^-$ ,  $\gamma \leq |w^T x + b|$  e consequentemente,  $\frac{|w^T x + b|}{\gamma} \geq 1$ . Assim, para  $x \in \mathcal{X}^+$  temos

$$\frac{w^T x + b}{\gamma} = \frac{|w^T x + b|}{\gamma} \geq 1,$$

e para  $x \in \mathcal{X}^-$ , temos

$$-\frac{w^T x + b}{\gamma} = \frac{|w^T x + b|}{\gamma} \geq 1.$$

Logo, definindo  $\bar{w} := \frac{w}{\gamma}$  e  $\bar{b} := \frac{b}{\gamma}$ , obtemos as desigualdades (1) e (2). □

A partir do Lema 1 temos que  $\mathcal{H}^+ := \{x \in \mathbb{R}^n \mid w^T x + b = 1\}$  e  $\mathcal{H}^- := \{x \in \mathbb{R}^n \mid w^T x + b = -1\}$  são os hiperplanos que definem a faixa que separa os conjuntos  $\mathcal{X}^+$  e  $\mathcal{X}^-$ .

**Proposição 1.** A projeção ortogonal de um vetor  $\bar{x} \in \mathbb{R}^n$  sobre um hiperplano afim  $\mathcal{H}(w, b)$ , é dada por

$$\text{proj}_{\mathcal{H}}(\bar{x}) = \bar{x} - \frac{w^T \bar{x} + b}{w^T w} w.$$

Além disso, a  $\text{proj}_{\mathcal{H}}(\bar{x})$  satisfaz a menor distância.

*Demonstração.* Sejam  $w \in \mathbb{R}^n$  o vetor normal ao hiperplano  $\mathcal{H}(w, b)$ ,  $\bar{z} \in \mathcal{H}(w, b)$  e  $x^*$  a projeção ortogonal de  $\bar{x}$  sobre  $\mathcal{H}(w, b)$ . Assim, temos que

$$w^T(x^* - \bar{z}) = 0 \quad (3)$$

e

$$\bar{x} - x^* = \lambda w \implies x^* = \bar{x} - \lambda w. \quad (4)$$

Substituindo (4) em (3), obtemos

$$\begin{aligned} 0 &= w^T(\bar{x} - \lambda w - \bar{z}) \\ &= w^T\bar{x} - \lambda w^Tw - w^T\bar{z}. \end{aligned}$$

Resolvendo para  $\lambda$  e como  $w^T\bar{z} = -b$ , temos

$$\lambda = \frac{w^T\bar{x} - w^T\bar{z}}{w^Tw} = \frac{w^T\bar{x} + b}{w^Tw}.$$

Portanto,

$$x^* = \bar{x} - \frac{w^T\bar{x} + b}{w^Tw}w.$$

Ademais, vamos provar que a  $\text{proj}_{\mathcal{H}}(\bar{x})$  satisfaz a menor distância, isto é,

$$\|\bar{x} - x^*\|_2 \leq \|\bar{x} - x\|_2,$$

para todo  $x \in \mathcal{H}(w, b)$ .

De fato, tomando  $u = \bar{x} - x^*$  e  $v = x^* - x$  observe que

$$\begin{aligned} u^Tv &= (\bar{x} - x^*)^T(x^* - x) \\ &= (\bar{x} - \bar{x} + \lambda w)^T(x^* - x) \\ &= \lambda w^T(x^* - x) \\ &= \lambda(w^Tx^* - w^Tx) \\ &= \lambda(-b - (-b)) \\ &= 0. \end{aligned}$$

Assim, temos

$$\|u + v\|^2 = \|u\|^2 + 2u^Tv + \|v\|^2 = \|u\|^2 + \|v\|^2,$$

ou seja,

$$\|\bar{x} - x\|^2 = \|\bar{x} - x^*\|^2 + \|x^* - x\|^2.$$

□

Utilizando a Proposição 1 podemos demonstrar o Lema 2, o qual estabelece a largura da faixa entre os hiperplanos separadores  $\mathcal{H}^+$  e  $\mathcal{H}^-$ .

**Lema 2.** *A distância entre os hiperplanos  $\mathcal{H}^+$  e  $\mathcal{H}^-$  é dada por  $\text{dist}(\mathcal{H}^+, \mathcal{H}^-) = \frac{2}{\|w\|}$ .*

*Demonstração.* Considere um ponto arbitrário  $\bar{x} \in \mathcal{H}^+$  e seja  $x^* \in \mathcal{H}^-$  a projeção ortogonal de  $\bar{x}$  sobre  $\mathcal{H}^-$ . Usando a Proposição 1, temos

$$x^* = \text{proj}_{\mathcal{H}^-}(\bar{x}) = \bar{x} - \frac{w^T \bar{x} + b + 1}{\|w\|^2} w. \quad (5)$$

Além disso, a distância entre dois conjuntos é definida por

$$\text{dist}(\mathcal{H}^+, \mathcal{H}^-) := \inf\{\|x^+ - x^-\| : x^+ \in \mathcal{H}^+ \text{ e } x^- \in \mathcal{H}^-\},$$

e como a  $\text{proj}_{\mathcal{H}^-}(\bar{x})$  satisfaz a menor distância entre  $\bar{x}$  e  $\mathcal{H}^-$ , e  $\mathcal{H}^+$  é paralelo a  $\mathcal{H}^-$ , temos que

$$\text{dist}(\mathcal{H}^+, \mathcal{H}^-) = \|\bar{x} - x^*\|. \quad (6)$$

Substituindo (5) em (6) obtemos

$$\begin{aligned} \text{dist}(\mathcal{H}^+, \mathcal{H}^-) &= \|\bar{x} - x^*\| \\ &= \left\| \bar{x} - \bar{x} + \frac{w^T \bar{x} + b + 1}{\|w\|^2} w \right\| \\ &= \frac{|w^T \bar{x} + b + 1|}{\|w\|^2} \|w\| \\ &= \frac{|w^T \bar{x} + b + 1|}{\|w\|}, \end{aligned}$$

e como  $\bar{x} \in \mathcal{H}^+$ ,  $w^T \bar{x} + b = 1$  implica

$$w^T \bar{x} = 1 - b,$$

concluindo que

$$\begin{aligned}\text{dist}(\mathcal{H}^+, \mathcal{H}^-) &= \frac{|1 - b + b + 1|}{\|w\|} \\ &= \frac{2}{\|w\|}.\end{aligned}$$

□

## 1.1 Formulação Matemática do Problema de Classificação - Margem Rígida

Encontrar o hiperplano que melhor separa os dados implica maximizar a largura da margem, isto é, maximizar  $\text{dist}(\mathcal{H}^+, \mathcal{H}^-) = \frac{2}{\|w\|}$ . Isso equivale a minimizar seu inverso  $\frac{1}{2}\|w\|$  ou ainda minimizar  $\frac{1}{2}\|w\|^2$ . De fato, seja  $w^* = \arg \max \frac{2}{\|w\|}$ . Então, para todo  $w \in \mathbb{R}^n$ ,

$$\frac{2}{\|w^*\|} \geq \frac{2}{\|w\|}$$

implica

$$\|w\| \geq \|w^*\|. \quad (7)$$

Logo,  $w^* = \arg \min \|w\|$ . Além disso, como  $\|\cdot\|$  é não negativa, elevando ao quadrado ambos os lados da desigualdade (7) temos que  $\|w\|^2 \geq \|w^*\|^2$  implica

$$\frac{1}{2}\|w\|^2 \geq \frac{1}{2}\|w^*\|^2.$$

Portanto,

$$\arg \max \frac{2}{\|w\|} = \arg \min \frac{1}{2}\|w\|^2.$$

Ademais, como a faixa deve separar os dados das duas classes, as seguintes restrições devem ser satisfeitas

$$\begin{aligned}w^T x + b &\geq 1, \text{ para todo } x \in \mathcal{X}^+, \\ w^T x + b &\leq -1, \text{ para todo } x \in \mathcal{X}^-.\end{aligned}$$

Considerando que  $\mathcal{X}^+ = \{x^i \in \mathcal{X} \mid y_i = 1\}$  e  $\mathcal{X}^- = \{x^i \in \mathcal{X} \mid y_i = -1\}$ , podemos



reescrever as restrições acima de uma forma mais compacta

$$y_i(w^T x^i + b) \geq 1, \quad i = 1, \dots, m.$$

Portanto, o problema de encontrar o hiperplano ótimo pode ser formulado da seguinte maneira

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.a.} \quad & y_i(w^T x^i + b) \geq 1, \quad i = 1, \dots, m, \end{aligned} \tag{8}$$

em que  $w \in \mathbb{R}^n$  e  $b \in \mathbb{R}$ .

O problema (8) possui função objetivo

$$f(w, b) = \frac{1}{2} \|w\|^2$$

convexa, e restrições lineares

$$g_i(w, b) = 1 - y_i(w^T x^i + b) \leq 0, \quad i = 1, \dots, m,$$

em que a função  $g : \mathbb{R}^{n+1} \rightarrow \mathbb{R}^m$  pode ser escrita da forma

$$g(w, b) = e - (YX^T w + by) \leq 0,$$


com  $e$  sendo o vetor cujas  $m$  componentes são todas iguais a 1,  $Y = \text{diag}(y_i)$ ,  $X = \text{diag}(x^i)$ ,  $y^T = [y_1 \dots y_m]$ ,  $w \in \mathbb{R}^n$  e  $b \in \mathbb{R}$ .

## 1.2 Formulação Matemática do Problema de Classificação - Margem Flexível (CSVM)

Situações reais dificilmente envolvem problemas cujos dados são linearmente separáveis. Em vista disso, faz-se necessário estender os conceitos e resultados estudados nas SVMs lineares de margem rígida para o caso de SVM com margem flexível, quando os dados não são linearmente separáveis. Para tanto, considere um conjunto de dados não linearmente separável como da Figura 4b, isto é, não existe um hiperplano separador.

Neste caso, temos que o conjunto viável

$$\{(w, b) \in \mathbb{R}^{n+1} \mid 1 - y_i(w^T x^i + b) \leq 0, \quad i = 1, \dots, m\}$$



(a) Dados linearmente separáveis. (b) Dados não linearmente separáveis.

Figura 4: Fonte: Deisenroth, Faisal e Ong [1]

é vazio e, portanto, a formulação dada pelo problema (8) não fornece um classificador.

Assim, no intuito de contornar esse problema utilizamos regularização para suavizar as margens, acrescentando variáveis de folga  $\xi_i \geq 0$  associadas aos dados de treinamento  $x_i$ , com  $i = 1, \dots, m$ , e permitindo, assim, uma flexibilização do problema de estimar as variáveis  $w$  e  $b$ . Em outras palavras, a restrição  $1 - y_i(w^T x^i + b) \leq 0$  é relaxada e substituída por  $1 - y_i(w^T x^i + b) \leq \xi_i$ , com  $\xi_i \geq 0$ . Cada variável de folga  $\xi_i$  mensura a distância que determinado dado  $x_i$  está do seu respectivo hiperplano separador, caso este dado esteja do lado errado.




Figura 5: Variáveis de folga  
Fonte: Deisenroth, Faisal e Ong [1]

Tal procedimento permite que pontos da classe positiva permaneçam fora do semiespaço  $\mathcal{S}^+ = \{x \in \mathbb{R}^n \mid w^T x + b \geq 1\}$  e/ou pontos da classe negativa fora do semiespaço  $\mathcal{S}^- = \{x \in \mathbb{R}^n \mid w^T x + b \leq -1\}$ .

Nesta formulação o hiperplano separador é denominado hiperplano de margem flexível

e as restrições dos hiperplanos separadores são reformuladas da seguinte maneira

$$w^T x^i + b \geq 1 - \xi_i, \text{ para todo } x^i \in \mathcal{X}^+, \quad (9)$$

$$w^T x^i + b \leq -1 + \xi_i, \text{ para todo } x^i \in \mathcal{X}^-. \quad (10)$$

Agora nosso objetivo é encontrar  $w$  e  $b$  ótimos de modo a obter um bom classificador. Primeiramente, observe que dados  $w$  e  $b$  arbitrários, podemos escolher  $\xi_i \geq 0$  de modo que as restrições (9) e (10) sejam satisfeitas. Para tanto, podemos definir

$$\xi_i = \begin{cases} \max\{0, 1 - w^T x^i - b\}, & \text{se } x^i \in \mathcal{X}^+, \\ \max\{0, 1 + w^T x^i + b\}, & \text{se } x^i \in \mathcal{X}^-. \end{cases}$$

Desse modo, para obter um bom classificador não basta apenas maximizar a margem definida pelos hiperplanos  $\mathcal{H}^+$  e  $\mathcal{H}^-$  e introduzir as variáveis de folga nas restrições, mantendo a mesma função objetivo, pois, como exemplificado por Krulikovski [3], a Figura 6 ilustra o hiperplano dado por  $w_0^T x + b_0 = 0$ , que não poder ser usado para classificar os dados, mas satisfaz as restrições (9) e (10).




Figura 6: Pensar.

Fonte: Krulikovski [3]

Portanto, para reformular o problema original de maximizar a margem é preciso também controlar o valor dessas variáveis de modo a estimular uma classificação correta, pois quanto maior o valor delas mais será permitido violar as restrições. Em vista disso, é acrescentada na função objetivo uma parcela que corresponde à penalização das vio-

lações e o problema (8) é reformulado da seguinte forma

$$\begin{aligned}
\min_{w,b,\xi} \quad & \frac{1}{2}\|w\|^2 + C \sum_{i=1}^m \xi_i \\
\text{s.a.} \quad & y_i(w^T x^i + b) \geq 1 - \xi_i, \quad i = 1, \dots, m, \\
& \xi_i \geq 0, \quad i = 1, \dots, m,
\end{aligned} \tag{11}$$

em que  $C > 0$  é um parâmetro de regularização que tem o objetivo de controlar a importância das variáveis de folga. O valor do parâmetro  $C$  que fornece uma boa classificação dos dados é escolhido de maneira heurística na fase de treinamento, geralmente a partir da natureza do problema. É devido a utilização desse parâmetro esta modelagem de SVM também é conhecida como C-SVM.

O termo  $C \sum_{i=1}^m \xi_i$  na função objetivo do problema (11) pode ser pensado como uma medida de erro de classificação, pois minimiza o valor das variáveis de folga e reduz desse modo o número de pontos classificados incorretamente. De fato, aumentando o valor do parâmetro  $C$  aumenta-se a penalização sobre a violação da restrição original do problema SVM. Por outro lado, diminuindo o valor de  $C$  o modelo se torna mais flexível a esse tipo de violação.

O problema de margem flexível (11), assim como o problema (8), também possui restrições lineares

$$\begin{aligned}
g_i(w, b, \xi) &= 1 - \xi_i - y_i(w^T x^i + b) \leq 0 \quad \text{e} \\
h_i(w, b, \xi) &= -\xi_i \leq 0, \quad i = 1, \dots, m,
\end{aligned}$$

e assim, o conjunto viável

$$\Omega = \{(w, b, \xi) \in \mathbb{R}^{n+1+m} \mid g_i(w, b, \xi) \leq 0, h_i(w, b, \xi) \leq 0, i = 1, \dots, m\}$$

é um poliedro não vazio.

Ademais, a função objetivo  $f$  é quadrática e limitada inferiormente em  $\Omega$ , pois

$$f(w, b, \xi) = \frac{1}{2}\|w\|^2 + \underbrace{C}_{>0} \sum_{i=1}^m \underbrace{\xi_i}_{\geq 0} \geq 0.$$

## 2 Conceitos de Otimização

Nesta seção abordaremos alguns conceitos e resultados de Otimização para o problema

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.a} \quad & g(x) \leq 0, \\ & h(x) = 0, \end{aligned} \tag{12}$$

em que a função objetivo  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  e as funções que definem as restrições  $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$  e  $h : \mathbb{R}^n \rightarrow \mathbb{R}^p$  são continuamente diferenciáveis. O conjunto

$$\Omega := \{x \in \mathbb{R}^n \mid g(x) \leq 0, h(x) = 0\}$$

é chamado de *conjunto viável* do problema (12), e os pontos de  $\Omega$  são chamados de *pontos viáveis*.

**Definição 3.** Dizemos que  $x^*$  é uma solução global do problema (12), ou seja, um *minimizador global* de  $f$  em  $\Omega$ , quando

$$f(x^*) \leq f(x)$$

para todo  $x \in \Omega$ .

**Definição 4.** Dizemos que  $x^* \in [-\infty, +\infty)$  definido por

$$x^* = \inf_{x \in \Omega} f(x)$$

é o *valor ótimo* do problema (12).

Uma classe especial de problemas de otimização se refere ao caso em que  $\Omega$  é um conjunto poliedral. Assim, dizemos que um conjunto viável é *poliedral* quando ele pode ser representado como o conjunto das soluções de um sistema finito de equações e inequações lineares. Por exemplo,

$$\Omega = \{x \in \mathbb{R}^n \mid Ax \leq b, Mx = r\},$$

em que  $A \in \mathbb{R}^{m \times n}$ ,  $M \in \mathbb{R}^{p \times n}$ ,  $b \in \mathbb{R}^m$ ,  $r \in \mathbb{R}^p$ . Neste contexto, dizemos que  $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ , com  $g(x) = Ax - b$ , e  $h : \mathbb{R}^n \rightarrow \mathbb{R}^p$ , com  $h(x) = Mx - r$ , são funções afins.

Se a função objetivo  $f$  for linear, (12) é chamado de problema de *programação linear*, e se  $f$  for uma função quadrática, (12) é chamado de problema de *programação quadrática*.

Ademais, quando  $\Omega$  é um conjunto convexo e  $f$  é uma função convexa, dizemos que (12) é um problema de *programação convexo*.

**Definição 5.** Dado  $\bar{x} \in \Omega$ , dizemos que uma restrição de desigualdade  $g_i$  é ativa em  $\bar{x}$  quando  $g_i(\bar{x}) = 0$ . Caso  $g_i(\bar{x}) < 0$ , dizemos que  $g_i$  é inativa em  $\bar{x}$ .

O conjunto dos índices das restrições de desigualdade ativas é denotado por

$$I(\bar{x}) = \{i \mid g_i(\bar{x}) = 0\}.$$

**Definição 6.** Um ponto  $x^* \in \mathbb{R}^n$  é dito *estacionário* para o problema (12) quando existirem  $\mu^* \in \mathbb{R}^m$ ,  $\lambda^* \in \mathbb{R}^p$  (*multiplicadores de Lagrange*) tais que

$$\begin{aligned} \nabla f(x^*) + \sum_{i=1}^m \mu_i^* \nabla g_i(x^*) + \sum_{i=1}^p \lambda_i^* \nabla h_i(x^*) &= 0, \\ g(x^*) &\leq 0, h(x^*) = 0, \\ \mu_i^* &\geq 0, \quad i = 1, \dots, m, \\ \lambda_i^* g_i(x^*) &= 0, \quad i = 1, \dots, p. \end{aligned} \tag{13}$$

As condições em (13) são conhecidas como condições de Karush-Kuhn-Tucker (KKT). Assim, um ponto é dito estacionário quando satisfaz as condições KKT. Sob determinadas hipóteses de qualificação, as condições KKT são satisfeitas em um ponto que seja minimizador.

**Definição 7.** Dizemos que as restrições  $g(x) \leq 0$  e  $h(x) = 0$  cumprem uma condição de qualificação em  $x^* \in \Omega$  quando, dada qualquer função diferenciável  $f$  que tenha mínimo em  $x^*$ , relativamente a  $\Omega$ , sejam satisfeitas as condições de otimalidade de KKT.

Logo, um ponto  $x \in \mathbb{R}^n$  é dito qualificado quando atende uma condição de qualificação. Vejamos então algumas condições de qualificação para o problema (12).

**Condição de qualificação de Slater:** Dizemos que a condição de qualificação de Slater é satisfeita quando  $h$  é linear, cada componente  $g_i$ ,  $i = 1, \dots, m$ , é convexa e existe  $\tilde{x} \in \Omega$  tal que  $h(\tilde{x}) = 0$  e  $g(\tilde{x}) < 0$ .

**Condição de qualificação de independência linear:** Dizemos que a condição de qualificação de independência linear (LICQ) é satisfeita em  $\bar{x}$  quando o conjunto formado pelos gradientes das restrições de igualdade e das restrições de desigualdade ativas é linearmente independente, isto é,

$$\{\nabla g_i(\bar{x}) \mid i \in I(\bar{x})\} \cup \{\nabla h_i(\bar{x}), i = 1, \dots, p\} \quad \text{é LI.}$$

**Teorema 1.** (KKT) *Seja  $x^* \in \mathbb{R}^n$  um minimizador local do problema (12) e suponha que seja satisfeita uma condição de qualificação. Então existem vetores  $\mu^* \in \mathbb{R}^m$  e  $\lambda^* \in \mathbb{R}^p$  tais que  $(x^*, \mu^*, \lambda^*)$  cumpre (13).*

É importante observar que se não for verificada nenhuma condição de qualificação para as restrições, podemos ter minimizadores que não cumprem KKT, o que dificulta a caracterização de tais pontos. Vejamos a seguir um exemplo que justifica essa afirmação.

**Exemplo 2.0.1.** Considere o problema

$$\begin{aligned} \min_x \quad & f(x) = x_1 \\ \text{s.a} \quad & g(x) = -x_1^3 + x_2 \leq 0, \\ & h(x) = -x_2 \leq 0. \end{aligned}$$

O ponto  $x^* = 0$  é o minimizador deste problema, mas não cumpre as condições KKT. De fato, observe que  $0 \leq x_2 \leq x_1^3$ , o que implica em  $f(x) = x_1 \geq 0 = f(x^*)$ , para todo ponto viável  $x$ .

No entanto,

$$\nabla f(x^*) = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \nabla g(x^*) = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \quad \text{e} \quad \nabla h(x^*) = \begin{pmatrix} 0 \\ -1 \end{pmatrix},$$

e, portanto, as condições KKT não são satisfeitas, pois não existem  $\mu^* \in \mathbb{R}$  e  $\lambda^* \in \mathbb{R}$  tais que

$$\begin{pmatrix} 1 \\ 0 \end{pmatrix} + \mu^* \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \lambda^* \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

### 3 Otimização Convexa

Em otimização uma hipótese com ótimas consequências é a convexidade, pois ela garante que pontos estacionários são minimizadores e permite concluir que minimizadores locais são globais. A partir disso, os problemas de classificação podem ser formulados em termos de otimização convexa. Os principais conceitos definidos neste capítulo são conjuntos convexos e funções convexas e a partir deles apresentamos alguns resultados importantes da análise convexa. Para desenvolvimento desse capítulo as principais referências utilizadas foram Izmailov e Solodov [2], Krulikovski [3] e Ribeiro e Karas [4].

### 3.1 Conjuntos Convexos

**Definição 8.** Um conjunto  $C \subset \mathbb{R}^n$  é dito convexo quando dados  $x, y \in C$ , o segmento  $[x, y] = \{(1-t)x + ty \mid t \in [0, 1]\}$  estiver inteiramente contido em  $C$ .

A Figura 7 apresenta a noção de convexidade de conjuntos, ilustrando um conjunto convexo e outro não convexo. Em outras palavras um conjunto convexo se caracteriza por conter todos os segmentos cujos extremos pertencem ao conjunto, o que não ocorre no segundo conjunto da Figura 7 por exemplo.




Figura 7: Exemplo de conjunto convexo e não convexo.  
Fonte: Krulikowski [3]

Alguns exemplos de conjuntos convexos são o conjunto vazio, o espaço  $\mathbb{R}^n$ , qualquer hiperplano do  $\mathbb{R}^n$  e um conjunto que contém um ponto só.

A seguir, apresentamos alguns resultados importantes da análise convexa.

**Lema 3.** Considere  $\|\cdot\|$  a norma euclidiana em  $\mathbb{R}^n$ . Sejam  $u, v \in \mathbb{R}^n$  com  $u \neq v$ . Se  $\|u\| = \|v\| = r$ , então  $\|(1-t)u + tv\| < r$ , para todo  $t \in (0, 1)$ .

*Demonstração.* Seja  $t \in (0, 1)$  e suponha que  $\|u\| = \|v\| = r$ . Aplicando a desigualdade triangular, temos

$$\|(1-t)u + tv\| \leq (1-t)\|u\| + t\|v\| = (1-t)r + tr = r.$$

Agora, suponha por absurdo que  $\|(1-t)u + tv\| = r$ . Então

$$(1-t)^2 u^T u + 2t(1-t)u^T v + t^2 v^T v = \|(1-t)u + tv\|^2 = r^2. \quad (14)$$

Como  $u^T u = v^T v = r^2$  e  $t \in (0, 1)$ , substituindo em (14) e desenvolvendo, obtemos

$$\begin{aligned} r^2 &= (1-2t+t^2)u^T u + (2t-2t^2)u^T v + t^2 v^T v \\ &= (1-2t+t^2)r^2 + (2t-2t^2)u^T v + t^2 r^2 \\ &= r^2 - 2tr^2 + t^2 r^2 + (2t-2t^2)u^T v + t^2 r^2. \end{aligned}$$



Evidenciando  $r^2$ , temos

$$(2t - 2t^2)r^2 = (2t - 2t^2)u^T v,$$

e, portanto,

$$r^2 = u^T v. \quad (15)$$

Assim, por (15),

$$\|u - v\|^2 = u^T u - 2u^T v + v^T v = r^2 - 2r^2 + r^2 = 0,$$

o que é uma contradição, pois por hipótese  $u \neq v$ .

Portanto, concluímos que  $\|(1 - t)u + tv\| < r$ , para todo  $t \in (0, 1)$ .  $\square$

Agora, dado um conjunto  $S \subset \mathbb{R}^n$  e um ponto  $z \in \mathbb{R}^n$ , considere o problema de encontrar um ponto de  $S$  mais próximo de  $z$ , em outras palavras, queremos minimizar a distância de um ponto a um conjunto. Assim, os próximos resultados garantem a existência da solução no caso de  $S$  ser um conjunto fechado e sua unicidade se, além de fechado,  $S$  for convexo. Tal solução é chamada de projeção de  $z$  sobre  $S$ , e denotada por  $\text{proj}_S(z)$ .

**Lema 4.** *Seja  $S \subset \mathbb{R}^n$  um conjunto fechado não vazio. Dado  $z \in \mathbb{R}^n$ , existe  $\bar{z} \in S$  tal que*

$$\|z - \bar{z}\| \leq \|z - x\|,$$

para todo  $x \in S$ .

*Demonstração.* Seja  $\alpha = \inf\{\|z - x\| \mid x \in S\}$ . Então, para cada  $n \in \mathbb{N}$ , existe  $x^n \in S$  tal que

$$\alpha \leq \|z - x^n\| \leq \alpha + \frac{1}{n}. \quad (16)$$

Em particular,  $\|z - x^n\| \leq \alpha + 1$ , para todo  $n \in \mathbb{N}$ . Logo, existe uma subsequência  $(x^{n^k})$  convergente, com  $k \in \mathbb{N}'$ , tal que  $x^{n^k} \rightarrow \bar{z}$ . Como  $S$  é fechado temos que  $\bar{z} \in S$ . Além disso,

$$\|z - x^n\| \rightarrow \|z - \bar{z}\|.$$

Mas, por (16), temos que  $\|z - x^n\| \rightarrow \alpha$ , e portanto, concluímos que  $\|z - \bar{z}\| = \alpha$ .  $\square$

**Lema 5.** *Seja  $S \subset \mathbb{R}^n$  um conjunto não vazio, convexo e fechado. Dado  $z \in \mathbb{R}^n$ , existe um único  $\bar{z} \in S$  tal que*

$$\|z - \bar{z}\| \leq \|z - x\|$$

*para todo  $x \in S$ .*

*Demonstração.* A existência é garantida pelo Lema 4. Para provar a unicidade suponha que existam  $\bar{z}, \tilde{z} \in S$ , com  $\bar{z} \neq \tilde{z}$ , tais que

$$\|z - \bar{z}\| \leq \|z - x\| \quad \text{e} \quad \|z - \tilde{z}\| \leq \|z - x\|, \quad (17)$$

para todo  $x \in S$ . Tomando  $x = \tilde{z}$  na primeira desigualdade e  $x = \bar{z}$  na segunda, obtemos

$$\|z - \bar{z}\| = \|z - \tilde{z}\|.$$

Por outro lado, o ponto  $z^* = \frac{\bar{z} + \tilde{z}}{2}$  pertence ao conjunto convexo  $S$ . Além disso, pelo Lema 3, com  $r = \|z - \bar{z}\| = \|z - \tilde{z}\|$  e  $t = 1/2$ , temos

$$\begin{aligned} \|z - z^*\| &= \|z - t(\bar{z} + \tilde{z})\| \\ &= \|z - t\bar{z} - t\tilde{z}\| \\ &= \|(1-t)(z - \bar{z}) + t(z - \tilde{z})\| \\ &< r, \end{aligned}$$

o que é uma contradição, pois por (17) teríamos

$$r = \|z - \bar{z}\| = \|z - \tilde{z}\| \leq \|z - z^*\| < r.$$

Portanto,  $\bar{z} = \tilde{z}$ .

□

No Lema 5 denotamos  $\bar{z} = \text{proj}_S(z)$ .

**Teorema 2.** *Sejam  $S \subset \mathbb{R}^n$  um conjunto não vazio, convexo e fechado,  $z \in \mathbb{R}^n$  e  $\bar{z} = \text{proj}_S(z)$ . Então,*

$$(z - \bar{z})^T(x - \bar{z}) \leq 0,$$

*para todo  $x \in S$ .*

*Demonstração.* Sejam  $x \in S$  um ponto arbitrário e  $\bar{z} = \text{proj}_S(z)$ . Pelo Lema 4  $\bar{z} \in S$  e,

dado  $t \in (0, 1)$ , pela convexidade de  $S$ , temos que  $(1 - t)\bar{z} + tx \in S$ . Assim,

$$\|z - \bar{z}\| \leq \|z - (1 - t)\bar{z} - tx\| = \|(z - \bar{z}) - t(x - \bar{z})\|.$$

Então,

$$\|z - \bar{z}\|^2 \leq \|(z - \bar{z}) - t(x - \bar{z})\|^2 = \|z - \bar{z}\|^2 - 2t(z - \bar{z})^T(x - \bar{z}) + t^2\|x - \bar{z}\|^2,$$

e como  $t > 0$ , temos

$$2(z - \bar{z})^T(x - \bar{z}) \leq t\|x - \bar{z}\|^2. \quad (18)$$

Passando o limite em (18) quando  $t \rightarrow 0$ , obtemos

$$(z - \bar{z})^T(x - \bar{z}) \leq 0,$$

completando a demonstração. □

O Teorema 2 estabelece uma condição necessária e suficiente para caracterizar a projeção. Este resultado é provado no lema seguinte.

**Lema 6.** *Sejam  $S \subset \mathbb{R}^n$  um conjunto não vazio, convexo e fechado e  $z \in \mathbb{R}^n$ . Se  $\bar{z} \in S$  satisfaz*

$$(z - \bar{z})^T(x - \bar{z}) \leq 0,$$

*para todo  $x \in S$ , então  $\bar{z} = \text{proj}_S(z)$ .*

*Demonstração.* Dado  $x \in S$  arbitrário, temos

$$\begin{aligned} \|z - \bar{z}\|^2 - \|z - x\|^2 &= z^T z - 2z^T \bar{z} + \bar{z}^T \bar{z} - z^T z + 2z^T x - x^T x \\ &= -2z^T \bar{z} + \bar{z}^T \bar{z} + 2z^T x - x^T x \\ &= (x - \bar{z})^T(2z - x - \bar{z}) \\ &= (x - \bar{z})^T(2(z - \bar{z}) - (x - \bar{z})) \\ &= 2(x - \bar{z})^T(z - \bar{z}) - (x - \bar{z})^T(x - \bar{z}) \\ &\leq 0. \end{aligned}$$

pois  $(x - \bar{z})^T(z - \bar{z}) \leq 0$  por hipótese, e  $(x - \bar{z})^T(x - \bar{z}) = \|x - \bar{z}\|^2 \geq 0$ .

Logo,

$$\|z - \bar{z}\|^2 - \|z - x\|^2 \leq 0,$$

e, então

$$\|z - \bar{z}\|^2 \leq \|z - x\|^2,$$

para todo  $x \in S$ .

Portanto,  $\bar{z} = \text{proj}_S(z)$ . □

O Lema 6 fornece uma condição necessária de otimalidade ao minimizar uma função em um conjunto convexo fechado.

**Teorema 3. (*Taylor de Primeira Ordem*)** [4, p.25] *Considere  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  uma função diferenciável e  $\bar{x} \in \mathbb{R}^n$ . Então podemos escrever*

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T(x - \bar{x}) + r(x),$$

com  $\lim_{x \rightarrow \bar{x}} \frac{r(x)}{\|x - \bar{x}\|} = 0$ .

**Lema 7.** *Sejam  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  uma função diferenciável e  $C \subset \mathbb{R}^n$  um conjunto convexo e fechado. Se  $x^* \in C$  é minimizador local de  $f$  em  $C$ , então*

$$\text{proj}_C(x^* - \alpha \nabla f(x^*)) = x^*,$$

para todo  $\alpha \geq 0$ .

*Demonstração.* Seja  $x^* \in C$  minimizador local de  $f$  em  $C$ . Fixando  $x \in C$ , como  $C$  é um conjunto convexo, temos

$$f(x^*) \leq f((1-t)x^* + tx), \quad (19)$$

para todo  $t \geq 0$  suficientemente pequeno. Pelo Teorema 3,

$$f(x^* + t(x - x^*)) = f(x^*) + t\nabla f(x^*)^T(x - x^*) + r(t), \quad (20)$$

em que  $\lim_{t \rightarrow 0} \frac{r(t)}{t} = 0$ . Dessa forma, por (19) e (20), temos

$$0 \leq f(x^* + t(x - x^*)) - f(x^*) = t\nabla f(x^*)^T(x - x^*) + r(t),$$

e portanto,

$$t\nabla f(x^*)^T(x - x^*) + r(t) \geq 0. \quad (21)$$

Dividindo por  $t$  e passando o limite quando  $t \rightarrow 0$  em (21), obtemos

$$\nabla f(x^*)^T(x - x^*) \geq 0.$$

Assim, dado  $\alpha \geq 0$ ,

$$(x^* - \alpha \nabla f(x^*) - x^*)^T(x - x^*) = -\alpha \nabla f(x^*)^T(x - x^*) \leq 0,$$

para todo  $x \in C$ .

Portanto, pelo Lema 6 concluímos que  $\text{proj}_C(x^* - \alpha \nabla f(x^*)) = x^*$ , para todo  $\alpha \geq 0$ .  $\square$

### 3.2 Funções Convexas

**Definição 9.** Seja  $C \subset \mathbb{R}^n$  um conjunto convexo. Dizemos que a função  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  é convexa em  $C$  quando

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y),$$

para todos  $x, y \in C$  e  $t \in [0, 1]$ .

A noção geométrica da Definição 9 é apresentada na Figura 8, em que qualquer arco do gráfico de uma função convexa está sempre abaixo do segmento que liga as extremidades.




Figura 8: Função Convexa.  
Fonte: Krulikowski [3]

**Observação 1.** Todo problema de maximização

$$\begin{aligned} \max_x \quad & f(x) \\ \text{s.a.} \quad & x \in \Omega \end{aligned}$$

pode ser transformado em um problema de minimização equivalente

$$\begin{aligned} \min_x \quad & -f(x) \\ \text{s.a.} \quad & x \in \Omega. \end{aligned}$$

**Definição 10.** Se  $C \subset \mathbb{R}^n$  é um conjunto convexo, dizemos que  $f : C \rightarrow \mathbb{R}$  é uma *função côncava* em  $C$ , quando a função  $(-f)$  é convexa em  $C$ .

Assim, maximizar uma função côncava num conjunto convexo equivale a minimizar uma função convexa num conjunto convexo.

O teorema seguinte justifica o fato da convexidade ser uma propriedade tão importante em otimização.

**Teorema 4.** *Sejam  $C \subset \mathbb{R}^n$  um conjunto convexo e  $f : C \rightarrow \mathbb{R}$  uma função convexa. Se  $x^* \in C$  é minimizador local de  $f$ , então  $x^*$  é minimizador global de  $f$ .*

*Demonstração.* Seja  $x^*$  um minimizador local de  $f$ . Então, existe  $\delta > 0$  tal que

$$f(x^*) \leq f(x),$$

para todo  $x \in B(x^*, \delta) \cap C$ .

Considere  $y \in C$ , tal que  $y \notin B(x^*, \delta)$ , e tome  $t \in (0, 1]$  de modo que  $t\|y - x^*\| < \delta$ . Assim, o ponto  $x = (1 - t)x^* + ty$  satisfaz

$$\|x - x^*\| = \|(1 - t)x^* + ty - x^*\| = \|x^* - tx^* + ty - x^*\| = t\|y - x^*\| < \delta,$$

e, portanto,  $x \in B(x^*, \delta) \cap C$ .

Desse modo, como  $f$  é uma função convexa, temos

$$f(x^*) \leq f(x) \leq (1 - t)f(x^*) + tf(y) = f(x^*) + t(f(y) - f(x^*)),$$

donde segue que  $f(x^*) \leq f(y)$ .

Portanto,  $x^*$  é minimizador global de  $f$ . □

A seguir apresentamos outra forma de caracterizar a convexidade de uma função quando temos hipóteses de diferenciabilidade.

**Teorema 5.** *Sejam  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  uma função diferenciável e  $C \subset \mathbb{R}^n$  um conjunto convexo. A função  $f$  é convexa em  $C$  se, e somente se,*

$$f(y) \geq f(x) + \nabla f(x)^T(y - x),$$

para todos  $x, y \in C$ .

*Demonstração.* Seja  $f$  uma função convexa. Para  $x, y \in C$  e  $t \in (0, 1]$  quaisquer, temos  $(1 - t)x + ty = x + t(y - x)$ . Assim, definindo  $d = y - x$ , temos que  $x + td \in C$  e

$$f(x + td) = f((1 - t)x + ty) \leq (1 - t)f(x) + tf(y),$$

logo

$$f(x + td) \leq f(x) + t(f(y) - f(x)),$$

o que implica em

$$f(y) - f(x) \geq \frac{f(x + td) - f(x)}{t}.$$

Passando o limite quando  $t \rightarrow 0^+$ , temos

$$f(y) - f(x) \geq \lim_{t \rightarrow 0^+} \frac{f(x + td) - f(x)}{t} = \nabla f(x)^T d = \nabla f(x)^T(y - x),$$

e, portanto,

$$f(y) \geq f(x) + \nabla f(x)^T(y - x).$$

Reciprocamente, considere  $z = (1 - t)x + ty$  e observe que

$$f(x) \geq f(z) + \nabla f(z)^T(x - z) \quad \text{e} \quad f(y) \geq f(z) + \nabla f(z)^T(y - z).$$

Agora, multiplicando a primeira desigualdade por  $(1 - t)$  e a segunda por  $t$ , obtemos

$$\begin{aligned}
(1 - t)f(x) + tf(y) &\geq (1 - t)(f(z) + \nabla f(z)^T(x - z)) + t(f(z) + \nabla f(z)^T(y - z)) \\
&\geq f(z) + \nabla f(z)^T(x - z) - tf(z) - t\nabla f(z)^T(x - z) + tf(z) + t\nabla f(z)^T(y - z) \\
&\geq f(z) + \nabla f(z)^T(x - z) + t\nabla f(z)^T(-x + z + y - z) \\
&\geq f(z) + \nabla f(z)^T(x - z) + t\nabla f(z)^T(y - x) \\
&\geq f(z) + \nabla f(z)^T(x - z) + t\nabla f(z)^T \frac{(z - x)}{t} \\
&\geq f(z) + \nabla f(z)^T(x - z) - \nabla f(z)^T(x - z) \\
&= f(z) \\
&= f((1 - t)x + ty).
\end{aligned}$$

Portanto, a função  $f$  é convexa em  $C$ . □

A seguir, apresentamos alguns resultados necessários para demonstrar o Teorema 8.

**Teorema 6. (*Taylor de Segunda Ordem*)** [4, p.26] Se  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  é uma função duas vezes diferenciável e  $\bar{x} \in \mathbb{R}^n$ , então

$$f(x) = f(\bar{x}) + \nabla f(\bar{x})^T(x - \bar{x}) + \frac{1}{2}(x - \bar{x})^T \nabla^2 f(\bar{x})(x - \bar{x}) + r(x),$$

$$\text{com } \lim_{x \rightarrow \bar{x}} \frac{r(x)}{\|x - \bar{x}\|^2} = 0.$$

**Teorema 7. (*Taylor com Resto de Lagrange*)** [4, p.26] Considere  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  uma função de classe  $\mathcal{C}^1$  e  $\bar{x}, d \in \mathbb{R}^n$ . Se  $f$  é duas vezes diferenciável no segmento  $(\bar{x}, \bar{x} + d)$ , então existe  $t \in (0, 1)$  tal que

$$f(\bar{x} + d) = f(\bar{x}) + \nabla f(\bar{x})^T d + \frac{1}{2}d^T \nabla^2 f(\bar{x} + td)d.$$

**Lema 8.** Sejam  $C \subset \mathbb{R}^n$  convexo,  $x \in \bar{C}$  e  $y \in \text{int } C$ . Então,  $(x, y] \subset \text{int } C$ .

*Demonstração.* Por demonstrar. □

**Teorema 8.** Sejam  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  uma função de classe  $\mathcal{C}^2$  e  $C \subset \mathbb{R}^n$  um conjunto convexo com interior não vazio. A função  $f$  é convexa em  $C$  se, e somente se, a Hessiana  $\nabla^2 f(x)$  é semidefinida positiva para todo  $x \in C$ .



*Demonstração.* Considere  $x \in \text{int } C$ . Então, dado  $d \in \mathbb{R}^n$  temos que  $x + td \in C$ , para  $t$  suficientemente pequeno. Portanto, pela convexidade de  $f$  e pelo Teorema 5, temos

$$f(x + td) \geq f(x) + t\nabla f(x)^T d,$$

e assim,

$$f(x + td) - f(x) - t\nabla f(x)^T d \geq 0. \quad (22)$$

Aplicando o Teorema 6 para  $f(x + td)$ , temos

$$f(x + td) = f(x) + t\nabla f(x)^T d + \frac{t^2}{2} d^T \nabla^2 f(x) d + r(t^2),$$

e substituindo em (22), obtemos

$$\frac{t^2}{2} d^T \nabla^2 f(x) d + r(t^2) \geq 0,$$

com  $\lim_{t \rightarrow 0} \frac{r(t^2)}{t^2} = 0$ .

Dividindo por  $t^2$  e passando o limite com  $t \rightarrow 0$ , temos

$$d^T \nabla^2 f(x) d \geq 0.$$

Agora, considere  $x \in C$  arbitrário. Como existe  $y \in \text{int } C$ , o Lema 8 garante que todos os pontos do segmento  $(x, y] \subset \text{int } C$ . Então, pelo que acabamos de provar, dados  $d \in \mathbb{R}^n$  e  $t \in (0, 1]$ , vale

$$d^T \nabla^2 f((1 - t)x + ty) d \geq 0.$$

Fazendo  $t \rightarrow 0^+$  e usando a continuidade de  $\nabla^2 f$ , obtemos

$$d^T \nabla^2 f(x) d \geq 0,$$

para todo  $x \in C$ .

Reciprocamente, dados  $x \in C$  e  $d \in \mathbb{R}^n$  tal que  $x + d \in C$ , pelo Teorema 7,

$$f(x + d) = f(x) + \nabla f(x)^T d + \frac{1}{2} d^T \nabla^2 f(x + td) d$$

para algum  $t \in (0, 1)$ . Como  $\nabla^2 f(x + td) \geq 0$ , concluímos que

$$f(x + d) \geq f(x) + \nabla f(x)^T d.$$

Logo, pelo Teorema 5,  $f$  é convexa.  $\square$

Em geral, a função objetivo dos problemas de SVM serão funções quadráticas. Assim, faz-se necessário mostrar que a função quadrática é convexa. Tal resultado é apresentado a seguir.

**Teorema 9.** *Seja  $C \in \mathbb{R}^n$  um conjunto convexo e  $Q$  uma matriz quadrada. Seja  $f : C \rightarrow \mathbb{R}$  tal que  $f(x) = x^T Q x$  é uma função quadrática. Então,  $f$  é convexa se, e somente se,  $Q$  é semidefinida positiva.*

*Demonstração.* Por demonstrar.  $\square$

## Referências

- [1] Peter Deisenroth, A. Aldo Faisal e Cheng Soon Ong. *Mathematics for Machine Learning*. Boston: Cambridge University Press, 2019.
- [2] Alexey Izmailov e Mikhail Solodov. *Otimização. Condições de Otimalidade. Elementos de Análise Convexa e de Dualidade*. 3ª ed. Vol. I. Rio de Janeiro: IMPA, 2014.
- [3] Evelin Heringer Manoel Krulikowski. “Análise Teórica de Máquinas de Vetores Suporte e Aplicação a Classificação de Caracteres”. Dissertação de Mestrado em Matemática. Universidade Federal do Paraná, 2017.
- [4] Ademir A. Ribeiro e Elizabeth W. Karas. *Otimização Contínua: Aspectos teóricos e computacionais*. Cengage Learning, 2013.